

Временной ряд — это статистический материал, собранный в разные моменты времени, о значении каких-либо параметров исследуемого процесса. Он представляет собой массив чисел, отражающих значения измеряемой динамической переменной с постоянным шагом по времени.

модель временного ряда - это теоретические правила формирования временного ряда, которые определяют его условное распределение

важные допущения:

- одномерный временной ряд
- относительно невысокая частота данных
- отсутствие дополнительной невременной информации

Модель отвечает на 3 вопроса:

1. Что в ряде закономерность (тренд? сезонность? зависимость от прошлого?)
2. Что в ряде шум (случайные колебания)?
3. Как из пункта 1 и 2 сделать прогноз на завтра/через неделю?

Любой ряд можно мысленно разложить на части:

1. Уровень (level) — примерно “вокруг какого числа” всё колеблется
2. Тренд (trend) — общий рост/падение со временем
3. Сезонность (seasonality) — повторяющийся рисунок (каждый месяц/год/день недели)
4. Шум (error/noise) — то, что случайно дрожит вокруг закономерности

ETS

“Последние наблюдения важнее старых. Поэтому я буду делать прогноз, как «среднее», но больше доверять свежим данным.”

E - Error

T - Trend

S - Seasonality

компоненты

- A (аддитивная),
- M (мультипликативная),
- Ad (аддитивная затухающая),
- N (нет компоненты).

Первая буква (Error): A или M

Это про то, как “шум” ведёт себя при изменении уровня:

- E = A, если разброс примерно одинаковый по всему ряду (шум “ ± 10 ” всегда).
- E = M, если разброс растёт вместе с уровнем (шум “ $\pm 10\%$ ”).

4.2. Вторая буква (Trend): N, A, Ad, M

- T = N, если тренда нет (ряд вокруг уровня).
- T = A, если есть примерно линейный рост/падение (скорость роста “плюс-минус постоянная”).
- T = Ad, если рост/падение замедляется (выход на плато). Это и есть “затухающий тренд” из обозначений.
- T = M используют, когда рост скорее “процентный” (не +5 каждый месяц, а $\times 1.03$ каждый месяц). На практике часто применяют при строго положительных рядах.

Стационарный ряд

Свойства стационарного ряда:

- У ряда отсутствует тренд.
- У ряда отсутствует сезонность.
- У ряда не изменяется дисперсия — расстояние временного ряда от среднего значения.

Для проверки стационарности аналитики также используются специальные тесты: критерий Дики–Фуллера или KPSS.

Согласно тесту Дики–Фуллера, если p-value значение теста меньше α , то ряд стационарен. Реализация теста есть в Python в пакете

Задачи программирования

Анализ данных

Разработка

Цель — сделать работающий продукт/функциональность (приложение, сайт, сервис).

Результат — интерфейс, функции, стабильная система, которую используют люди.

Задачи анализа данных

Data Science (наука о данных)

Data Analytics (аналитика)

Что делает: анализирует данные, находит закономерности, готовит отчеты, отвечает на бизнес-вопросы.

Результат: дашборд, отчет, метрики, интерпретация “почему так произошло”.

Data Engineering (инженерия данных)

вопросы к лекции:

1. Чем отличается цель и результат в разработке и в анализе данных?
2. Приведи примеры задач для Data Analyst / Data Scientist / Data Engineer.

NumPy

Особый объект - NumPy Array

свойства

1. **Однотипность:** элементам не надо хранить “разный тип/структуру” как в списках Python.
2. **Плотное хранение в памяти:** элементы лежат рядом, удобно “пробегать” процессору.
3. **Векторизация:** операции вроде $a + 5$, $a * b$, $\text{np.sqrt}(a)$ выполняются сразу над всем массивом, без твоих циклов for.

что можно делать с массивом:

1. $a + 2 \rightarrow$ ко всем элементам прибавится 2
2. $a * 3 \rightarrow$ все умножится на 3
3. операции по осям:
 - $\text{axis}=0$ — считаем “по столбцам” (сжимаем строки)
 - $\text{axis}=1$ — считаем “по строкам” (сжимаем столбцы)
4. срезы:
 $a[i, j]$ — элемент в строке i , столбце j
5. булевы маски
 $\text{mask} = a > 0$
 $a[\text{mask}] \rightarrow$ вернет только элементы, которые подходят условию

Pandas

Таблица 2. Признаки по природе данных (что лежит в ячейках)

Тип	Подтип	Описание	Примеры	Pandas dtype (часто)	EDA-графики	Подготовка для ML (типично)
Числовые	Непрерывные	Любые значения на интервале	цена, температура, рост	float64	hist, boxplot, scatter	scaling (stand/minmax), логарифм при перекосе
Числовые	Дискретные	Счетные значения	кол-во покупок, клики	int64	bar/hist, boxplot	иногда scaling, иногда как категорию (если мало значений)
Категориальные	Номинальные	Категории без порядка	город, цвет, страна	object / category	bar chart (countplot)	one-hot / target encoding (осторожно)
Категориальные	Порядковые	Категории с порядком	low<mid<high, размер	object / category	bar chart по уровням	ordinal encoding (1,2,3...), важно сохранить порядок
Категориальные	Бинарные	Два значения	0/1, yes/no	bool/int64	bar (доли)	оставить как 0/1, проверить дисбаланс
Временные	—	Дата/время	2025-12-28 12:00	datetime64[ns]	line plot по времени	извлекать компоненты (month, dow), лаги, rolling
Текстовые	—	Свободный текст	отзывы, описания	object	длина текста, топ-слов	TF-IDF / эмбединги / count-vectorizer
Гео	—	Координаты/локации	lat/lon, район	float64/object	scatter на карте/плоскости	расстояния, кластеризация, геохеш
Мультимодальные	—	Не таблица "в лоб"	картинки/звук	часто пути (строки)	зависит	фичи-эмбединги из моделей/экстракторов

Таблица 1. Признаки по роли в задаче (что это за столбец)

Тип признака	Что означает	Примеры	Как обычно используют	Частые ошибки
X (features)	Описания объекта, "входы"	age, price, city, pclass	Анализ зависимостей, построение модели	Путать с таргетом
y (target)	Целевая переменная (что предсказываем/объясняем)	Survived, Churn, Sales	Отделяется от X, по ней считаются метрики	Случайно оставить в X (утечка)
ID / ключ	Идентификатор объекта	user_id, order_id	Для merge, поиска строк	Использовать как фичу (переобучение/мусор)
Дата/время события	Момент события/наблюдения	date, timestamp	Индекс ряда, построение временных признаков	Оставить как строку, не перевести в datetime
Служебные столбцы	Тех. поля: источник, версия, флаг	source, is_test, row_num	Контроль качества, фильтры	Мешают модели, если не удалить

Временной ряд — это статистические данные, проиндексированные некоторыми временными отметками.

цель анализа: хотим уметь предсказывать последующие (будущие) значения по предыдущим (прошлым, уже имеющимся)

составим условное распределение:

$$y_t \mid y_{t-1}, y_{t-2}, \dots, y_1 \sim ?$$

Модели временных рядов - теоретические правила формирования временного ряда, которые определяют его условное распределение.

Одной из важных задач анализа данных с временной отметкой является возможность выделения статического временного маркера и переход к обычной задаче анализа невременных данных.

Компоненты ETS

ETS предполагает, что ряд можно описать компонентами:

- Error (ошибка/шум)
- Trend (тренд)
- Seasonality (сезонность)

Кодировка моделей ETS: A / M / Ad / N

- A — аддитивная компонента
- M — мультипликативная
- Ad — аддитивная затухающая (damped)
- N — компоненты нет

Первая буква (Error): A или M

Это про то, как “шум” ведёт себя при изменении уровня:

- E = A, если разброс примерно одинаковый по всему ряду (шум “±10” всегда).
- E = M, если разброс растёт вместе с уровнем (шум “±10%”).

4.2. Вторая буква (Trend): N, A, Ad, M

- T = N, если тренда нет (ряд вокруг уровня).
- T = A, если есть примерно линейный рост/падение (скорость роста “плюс-минус постоянная”).
- T = Ad, если рост/падение замедляется (выход на плато). Это и есть “затухающий тренд” из обозначений.
- T = M используют, когда рост скорее “процентный” (не +5 каждый месяц, а $\times 1.03$ каждый месяц). На практике часто применяют при строго положительных рядах.

ETS (ANN)

Блок	ETS (ANN)
Наблюдаемый ряд	y_t — наблюдаемый ряд. Лекция 9. Временные ряды.pdf
Компоненты модели (смысл)	Только уровень l_t + шум u_t (без тренда и сезонности). Лекция 9. Временные ряды.pdf
Уравнение наблюдения (как получается y_t)	$y_t = l_{t-1} + u_t$. Лекция 9. Временные ряды.pdf
Предпосылки (ошибки и обновления состояний)	$u_t \sim \mathcal{N}(0, \sigma^2)$, независимы; $l_t = l_{t-1} + \alpha u_t$. Лекция 9. Временные ряды.pdf
Параметры модели (что надо оценить/задать)	3 параметра: α, σ^2, l_0 . Лекция 9. Временные ряды.pdf
Условное распределение $y_t \mid y_{t-1}, y_1$	Так как u_t нормальная и независимая, то $y_t \mid \text{прошлое} \sim \mathcal{N}(l_{t-1}, \sigma^2)$. (Основано на $y_t = l_{t-1} + u_t$ и $u_t \sim \mathcal{N}(0, \sigma^2)$). Лекция 9. Временные ряды.pdf
Корреляция (пример из лекции: $\text{corr}(y_1, y_2)$)	В лекции выведено: $\text{corr}(y_1, y_2) = \frac{\alpha}{\sqrt{\alpha^2 + 1}}$. Лекция 9. Временные ряды.pdf
Оценка параметров (как подбирают α, σ^2, l_0 и т.д.)	Функция правдоподобия в нашем случае: $L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_k) = f(x_1, \theta_1, \theta_2, \dots, \theta_k) \cdot f(x_2 x_1, \dots) \cdot \dots \cdot f(x_n x_{n-1}, \dots, x_1, \theta_1, \theta_2, \dots, \theta_k)$

ETS(ANN) — Simple Exponential Smoothing

Модель: $y_t = l_{t-1} + u_t$, обновление уровня $l_t = l_{t-1} + \alpha u_t$, где $u_t \sim \mathcal{N}(0, \sigma^2)$. Лекция 9. Временные ряды.pdf

Параметр	Обозначение	Что означает	Где используется в модели	Как влияет на поведение
Сглаживание уровня	α	Насколько сильно новый "шок/ошибка" u_t меняет уровень l_t	$l_t = l_{t-1} + \alpha u_t$ Лекция 9. Временные ряды.pdf	$\alpha \uparrow \rightarrow$ уровень быстрее подстраивается (меньше сглаживание); $\alpha \downarrow \rightarrow$ сильнее сглаживание, реакция медленнее
Дисперсия шума	σ^2	Разброс случайной ошибки u_t	$u_t \sim \mathcal{N}(0, \sigma^2)$ Лекция 9. Временные ряды.pdf	$\sigma^2 \uparrow \rightarrow$ ряд "шумнее", интервалы прогноза шире
Начальный уровень	l_0	Стартовая оценка уровня (до наблюдений)	Начальное условие для рекурсии уровней Лекция 9. Временные ряды.pdf	Сильно влияет на первые прогнозы/первые состояния, дальше влияние обычно уменьшается

$$\begin{aligned}
 y_1 &= l_0 + u_1 \Rightarrow u_1 = y_1 - l_0 \\
 l_1 &= l_0 + \alpha \cdot u_1 \Rightarrow l_1 = l_0 + \alpha(y_1 - l_0) \\
 y_2 &= l_1 + u_2 \Rightarrow u_2 = y_2 - l_1 = y_2 - (l_0 + \alpha(y_1 - l_0)) \\
 l_2 &= l_1 + \alpha \cdot u_2 \Rightarrow l_2 = \\
 &= l_0 + \alpha(y_1 - l_0) + \alpha(y_2 - (l_0 + \alpha(y_1 - l_0))) \\
 y_3 &= l_2 + u_3, \quad u_3 \sim \mathcal{N}(0, \sigma^2) \Rightarrow
 \end{aligned}$$

$$y_3 \sim \mathcal{N}(l_0 + \alpha(y_1 - l_0) + \alpha(y_2 - (l_0 + \alpha(y_1 - l_0))), \sigma^2)$$

$$\begin{aligned}
 y_1 &= l_0 + u_1 \Rightarrow D(y_1) = D(l_0 + u_1) = D(u_1) = \sigma^2 \\
 y_2 &= l_1 + u_2 \Rightarrow D(y_2) = D(l_1 + u_2) = D(l_0 + \alpha \cdot u_1 + u_2) \\
 &= D(\alpha \cdot u_1 + u_2) = \alpha^2 D(u_1) + D(u_2) = (\alpha^2 + 1)\sigma^2
 \end{aligned}$$

$$\begin{aligned}
 \text{cov}(y_1; y_2) &= \text{cov}(l_0 + u_1; l_0 + \alpha \cdot u_1 + u_2) = \text{cov}(u_1; \alpha \cdot u_1 + u_2) \\
 &= \text{cov}(u_1; \alpha \cdot u_1) + \text{cov}(u_1; u_2) = \alpha \cdot \text{cov}(u_1; u_1) = \alpha \sigma^2
 \end{aligned}$$

$$\text{corr}(y_1; y_2) = \frac{\text{cov}(y_1; y_2)}{\sqrt{D(y_1)} \cdot \sqrt{D(y_2)}} = \frac{\alpha \sigma^2}{\sqrt{\sigma^2} \cdot \sqrt{(\alpha^2 + 1)\sigma^2}} = \frac{\alpha}{\sqrt{\alpha^2 + 1}}$$

ETS (AAA)

Блок	ETS (AAA)
Наблюдаемый ряд	y_t — наблюдаемый ряд. Лекция 9. Временные ряды.pdf
Компоненты модели (смысл)	Уровень l_t + тренд b_t + сезонность s_t + шум u_t . Лекция 9. Временные ряды.pdf
Уравнение наблюдения (как получается y_t)	$y_t = l_{t-1} + b_{t-1} + s_{t-12} + u_t$. Лекция 9. Временные ряды.pdf
Предположки (ошибки и обновления состояний)	$u_t \sim \mathcal{N}(0, \sigma^2)$, независимы; $l_t = l_{t-1} + \alpha u_t$; $b_t = b_{t-1} + \beta u_t$; $s_t = s_{t-12} + \gamma u_t$. Лекция 9. Временные ряды.pdf
Параметры модели (что надо оценить/задать)	17 параметров: $\sigma^2, \alpha, \beta, \gamma, l_0, b_0, s_0, s_{-1}, s_{-2}, \dots, s_{-10}$. Лекция 9. Временные ряды.pdf
Условное распределение $y_t \mid y_{t-1}, y_1$	Аналогично: $y_t \mid \text{прошлое} \sim \mathcal{N}(l_{t-1} + b_{t-1} + s_{t-12}, \sigma^2)$. (Из уравнения наблюдения и нормальности ошибок.)
Корреляция (пример из лекции: $\text{corr}(y_1, y_2)$)	В слайдах это оставлено как упражнение ("необходимо посчитать корреляцию...", без готового вывода). Лекция 9. Временные ряды.pdf
Оценка параметров (как подбирают α, σ^2, l_0 и т.д.)	Подход тот же: ММП по условным распределениям (идея такая же, как в ANN, просто параметров больше).

ETS(AAA) — уровень + тренд + сезонность (все аддитивно)				
Модель: $y_t = l_{t-1} + b_{t-1} + s_{t-12} + u_t$, обновления $l_t = l_{t-1} + \alpha u_t$, $b_t = b_{t-1} + \beta u_t$, $s_t = s_{t-12} + \gamma u_t$, $u_t \sim \mathcal{N}(0, \sigma^2)$. Лекция 9. Временные ряды.pdf				
Параметр	Обозначение	Что означает	Где используется в модели	Как влияет на поведение
Сглаживание уровня	α	Как быстро меняется уровень l_t при новой ошибке	$l_t = l_{t-1} + \alpha u_t$ Лекция 9. Временные ряды.pdf	$\alpha \uparrow \rightarrow$ уровень быстрее реагирует; $\alpha \downarrow \rightarrow$ сильнее сглаживание
Сглаживание тренда	β	Как быстро меняется тренд b_t (скорость роста/падения)	$b_t = b_{t-1} + \beta u_t$ Лекция 9. Временные ряды.pdf	$\beta \uparrow \rightarrow$ тренд "гибче", быстрее подстраивается; $\beta \downarrow \rightarrow$ тренд более стабильный
Сглаживание сезонности	γ	Как быстро обновляется сезонный компонент s_t	$s_t = s_{t-12} + \gamma u_t$ Лекция 9. Временные ряды.pdf	$\gamma \uparrow \rightarrow$ сезонность быстрее меняется; $\gamma \downarrow \rightarrow$ сезонность более "постоянная"
Дисперсия шума	σ^2	Разброс ошибки u_t	$u_t \sim \mathcal{N}(0, \sigma^2)$ Лекция 9. Временные ряды.pdf	$\sigma^2 \uparrow \rightarrow$ больше шум, шире интервалы прогноза
Начальный уровень	l_0	Стартовый уровень ряда	Начальное условие для l_t Лекция 9. Временные ряды.pdf	Влияет на первые прогнозы/состояния
Начальный тренд	b_0	Стартовая скорость изменения (наклон)	Начальное условие для b_t Лекция 9. Временные ряды.pdf	Влияет на начальный "наклон" прогноза
Начальные сезонные состояния	$s_0, s_{-1}, \dots, s_{-10}$	Стартовые сезонные эффекты для периода (в лекции период 12)	Нужны, чтобы считать s_{t-12} в начале ряда Лекция 9. Временные ряды.pdf	Задают "рисунок" сезонности в начале, влияют на первые сезонные прогнозы
Итого параметров AAA (в лекции): 17 — $\sigma^2, \alpha, \beta, \gamma, l_0, b_0$ и 11 сезонных начальных значений $s_0, \dots, s_{-10}$. Лекция 9. Временные ряды.pdf				

сумма: $m_t = l_t + b_t$

$$m_t = m_{t-1} + (\alpha + \beta) u_t$$

$$y_t = m_{t-1} + s_{t-12} + u_t$$

① подставим $t=1$:

$$y_1 = m_0 + s_{-11} + u_1$$

$$u_1 = y_1 - (m_0 + s_{-11})$$

② подставим $t=2$:

$$y_2 = m_1 + s_{-10} + u_2$$

$$u_2 = y_2 - (m_1 + s_{-10})$$

$$m_2 = m_1 + (\alpha + \beta) u_2$$

③ подставим $t=3$:

$$y_3 = m_2 + s_{-9} + u_3 \quad u_3 \sim \mathcal{N}(0, \sigma^2)$$

$$y_3 = \underbrace{m_2}_{m_1 + (\alpha + \beta)(y_2 - (m_1 + s_{-10}))} + s_{-9} + u_3$$

$$m_1 = m_0 + (\alpha + \beta)(y_1 - (m_0 + s_{-11}))$$

$$y_3 = m_0 + (\alpha + \beta)(y_1 - (m_0 + s_{-11})) + (\alpha + \beta)(y_2 - (m_0 + (\alpha + \beta)(y_1 - (m_0 + s_{-11})) + s_{-10})) + s_{-9} + u_3$$

$$y_3 \sim (\dots, \sigma^2)$$

Корреляция $\text{corr}(y_1, y_2)$

$$y_1 = m_0 + s_{-11} + u_1$$

$$y_2 = m_1 + s_{-10} + u_2 \quad m_1 = m_0 + (\alpha + \beta) u_1$$

$$y_2 = m_0 + (\alpha + \beta) u_1 + s_{-10} + u_2$$

$$D(y_1) = D(u_1) = \sigma^2$$

$$D(y_2) = D(m_0 + (\alpha + \beta) u_1 + s_{-10} + u_2) = D((\alpha + \beta) u_1 + u_2) = (\alpha + \beta)^2 D(u_1) + D(u_2) = ((\alpha + \beta)^2 + 1) \sigma^2$$

$$\text{cov}(y_1, y_2) = \text{cov}(u_1, (\alpha + \beta) u_1 + u_2) = \text{cov}(u_1, (\alpha + \beta) u_1) + \text{cov}(u_1, u_2) = (\alpha + \beta) \text{cov}(u_1, u_1) + 0 = (\alpha + \beta) \sigma^2$$

$$\text{corr}(y_1, y_2) = \frac{\text{cov}(y_1, y_2)}{\sqrt{D(y_1) D(y_2)}} = \frac{(\alpha + \beta) \sigma^2}{\sqrt{\sigma^2 ((\alpha + \beta)^2 + 1)}} = \frac{(\alpha + \beta)}{\sqrt{(\alpha + \beta)^2 + 1}}$$

ARIMA — класс моделей для прогнозирования временных рядов, когда будущее значение зависит от:

- прошлых значений ряда,
- прошлых “ошибок/шоков”.

Главная цель: получить y_{t+h} (прогноз на h шагов) и часто ещё интервалы прогноза.

2) Расшифровка ARIMA(p, d, q)

ARIMA состоит из трёх частей:

2.1. AR (AutoRegressive) — p

Авторегрессия: текущее значение зависит от нескольких прошлых значений.

2.2. I (Integrated) — d

Интегрирование = сколько раз мы берём разности, чтобы сделать ряд “более стационарным”.

- d=0: разности не берём
- d=1: берём $\Delta y_t = y_t - y_{t-1}$
- d=2: разности ещё раз

Идея: если в ряду тренд, то разности его часто убирают.

2.3. MA (Moving Average) — q

Скользящее среднее по ошибкам: текущее значение зависит от прошлых ошибок:

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

4) Что такое стационарность (почему про неё говорят с ARIMA)

В классическом понимании стационарный ряд:

- имеет примерно постоянное среднее,
- постоянную дисперсию,
- зависимости не “уплывают” со временем.


ARIMA обычно строят так:

- если ряд не стационарен → делаем разности (d) → получаем ближе к стационарному → применяем ARMA.


Фундаментальные признаки систем с самоорганизованной критичностью (сложных систем):

- Открытость — существует постоянный приток/отток вещества/энергии/информации
- Диссипативность — существуют потери вещества/энергии/информации
- Неравновесность — число неустойчивых элементов системы существенно превышает число устойчивых
- Лавина-подобное поведение — наблюдается распространение вещества/энергии/информации всех масштабов

Неоднородный временной ряд — это временной ряд $\{\xi t\}$, характеризующийся неожиданными (маловероятными) и/или экстраординарными (выделяющимися из ряда родственных значений) значениями



Неоднородный временной ряд, демонстрирующий непрерывный (фазовый переход второго рода) выход системы в критическое состояние



Неоднородный временной ряд, демонстрирующий непрерывный (фазовый переход первого рода) выход системы в критическое состояние

строение: докритическая, мера раннего обнаружения, критическая точка, критическое состояние, релаксация

2) Формула (что обычно подразумевают под ACF)

Автокорреляция на лаге k :

$$\rho(k) = \text{Corr}(y_t, y_{t-k})$$

То есть это **обычная корреляция**, но между рядом и его же версией, сдвинутой на k .

- $\rho(0) = 1$ всегда (ряд идеально коррелирует сам с собой без сдвига)
- $\rho(k)$ обычно считают для $k = 1, 2, 3, \dots$

Скользящее окно — это способ считать статистики/признаки по временном ряду не по всему ряду сразу, а по кусочкам фиксированной длины, которые “едут” по времени.

Берем значения (в размер окна) - считаем среднее - обычная граница
скользящее - расширяющаяся область

Фрактальность

Фрактальность — термин, описывающий внутреннюю структуру объекта, который обладает свойством самоподобия и самоаффинности: любая маленькая часть объекта похожа на объект в целом (целое имеет ту же форму, что и одна или более частей).

Ряд ξ_t называется фрактальным (самоаффинным), если существует скейлинговая экспонента $H > 0$, такая что для любого масштаба времени $s > 0$ ряды ξ_t и $s^{-H}\xi_{st}$ имеют одно и то же вероятностное распределение (в лекции это записано как равенство по распределению). Лекция_11_Неоднородные_временные_ряды_Часть_2.pdf

Машинное обучение - наука, о поиске закономерностей в данных с помощью компьютера и математики.

данные

размечанные

неразмечанные

данные x , y которых есть ответ Y

есть только x , y которых нет ответа

обучение с учителем

обучение без учителя

Вводятся обозначения: Лекция 6. Введение в машинное обучение.pdf

- X — множество объектов в пространстве признаков
- Y — область значений целевой переменной

Суть ML в этих терминах: есть неизвестная зависимость $f: X \rightarrow Y$

которую мы хотим максимально точно приблизить, используя обучающую выборку: $\{(X_i, y_i)\}_{i=1}^n$

6) Обучение без учителя: что происходит

В unsupervised learning:

- есть X ,
- нет правильных ответов Y ,
- поэтому задача — найти "разумную структуру" в данных. Лекция 6. Введение в машинное обучение.pdf

4.1 Регрессия (supervised)

- Целевая переменная Y .
- Нужно восстановить функциональную зависимость $f: X \rightarrow Y$.

Примеры из лекции: предсказание стоимости жилья, времени доставки, спроса на такси.

4.2 Классификация (supervised)

- Y — набор классов (в лекции показано как $Y \subseteq \{0,1\}^n$ — идея кодирования классов).
- Нужно предсказать, к какому классу относится объект (часто в виде вероятностей по классам).

Примеры: отток клиентов/сотрудников, классификация клеток на здоровые/опухолевые, съедобность гриба.

4.3 Кластеризация (unsupervised)

- Нужно разбить объекты на группы без заранее известных правильных меток так, чтобы объекты внутри группы были более похожи друг на друга, чем объекты разных групп.

Примеры: сегментация аудитории, типы клеток в секвенировании, сообщества в соцграфе, смесь распределений.



Метрические алгоритмы — алгоритмы, основанные на вычислении сходства между объектами с помощью метрики.

Идея KNN:

1. На вход подаётся вектор признаков нового объекта.
2. Находим K ближайших объектов из обучающей выборки, для которых ответ известен.
3. Делаем предсказание:
 - регрессия: усредняем ответы соседей
 - классификация: голосуем по классам (можно и с весами)

Разбиение выборки

1. Training sample — обучающая (на ней учим модель)
2. Validation sample — валидационная (на ней подбирают гиперпараметры по метрикам)
3. Test sample — тестовая (на ней оценивают финальное качество)

Кросс-валидация — это способ разделять данные на train/validation по алгоритму, чтобы оценка качества была стабильнее.

Идея k-fold CV:

1. делим выборку на k частей (folds)
2. k-1 частей → обучение, 1 часть → валидация
3. повторяем k раз, каждый раз выбирая другой fold как валидацию
4. метрики усредняем

Плюсы кросс-валидации:

- погрешность оценки ниже (используется весь набор)
- можно лучше подобрать гиперпараметры

Минусы:

- обучение выполняется k раз → может быть долго для тяжёлых моделей

1. Понять задачу: регрессия или классификация
2. Подготовить признаки X и таргет y
3. Сделать разбиение train/val/test
4. Препроцессинг (пропуски, кодирование категорий, масштабирование чисел)
5. Обучить базовую модель (baseline)
6. Подобрать гиперпараметры по validation (или через CV)
7. Оценить final на test и зафиксировать результат

5.1 Confusion matrix (матрица ошибок) для бинарной классификации

- TP: правильно предсказали 1
- TN: правильно предсказали 0
- FP: ложная тревога (предсказали 1, а там 0)
- FN: пропуск (предсказали 0, а там 1)

5.2 Основные метрики


- **Accuracy** = $\frac{TP+TN}{TP+TN+FP+FN}$
- **Precision** = $\frac{TP}{TP+FP}$ — "насколько чисто ловим 1"
- **Recall** = $\frac{TP}{TP+FN}$ — "сколько единиц не пропустили"
- F1 = гармоническое среднее precision и recall

Распределение — правило, позволяющее находить вероятность попадания случайной величины в любой интервал;

Функцией распределения случайной величины X называется функция $F(x)$, выражающая для каждого x вероятность того, что случайная величина X примет значение, меньшее x .

Функцией плотности (плотностью распределения или просто плотностью) $f(x)$ непрерывной случайной величины X называется производная ее функции распределения.

Вероятность попадания случайной величины в интервал $[a, b]$:



алгоритмы в ML, связанные с нормальным распределением:

- Наивный Байесовский классификатор
- Модели на основе МНК
- Квадратичный дискриминантный анализ
- Линейный дискриминантный анализ

параметры в целом, — это численные величины, характеризующие особенности поведения величины, к которой они относятся

параметры

конкретизируют и наделяют смыслом распределения, которые сами по себе скорее представляют шаблоны поведения модели, нежели конкретную модель



Важно: для непрерывной СВ вероятность ровно одного значения:

$$P(X = a) = 0$$

Статистическая гипотеза

Это формализованное утверждение о данных/распределении/параметрах, которое можно проверить на выборке.

Статистический критерий (test)

Это “правило принятия решения”, которое:

- строит статистику (число) по данным,
- сравнивает её с теоретическим распределением/порогом,
- даёт решение: отклоняем H_0 или не отклоняем H_0 .

p-value — это вероятность (при условии, что H_0 верна) получить результат не менее экстремальный, чем наблюдаемый.

Типовое правило:

- если $p < \alpha$ (например, $\alpha=0.05$), то отклоняем H_0 ,
- иначе не отклоняем H_0 .

Ошибки I и II рода

- Ошибка I рода: отклонили H_0 , хотя она верна.
- Ошибка II рода: не отклонили H_0 , хотя она ложна.

t - test - проверка гипотез о средних значениях

1.1. One-sample t-test (одна выборка)

Проверяем:

$$H_0 : \mu = \mu_0$$

1.2. Two-sample t-test (две независимые выборки)

Например, A/B тест: группа A и группа B — разные люди.

$$H_0 : \mu_A = \mu_B$$

1.3. Paired t-test (связные выборки)

Это “до/после” для одних и тех же объектов (одни люди до лечения и после).

Проверяем среднее разностей:

$$d_i = x_i - y_i, \quad H_0 : \mathbb{E}[d] = 0$$

то что требуется для т-теста:

Нормальность

Гомогенность дисперсий (равенство дисперсий) (если не равны, то используется Welch t-test)

Раздел 3. χ^2 (хи-квадрат) гипотезы

1) Goodness-of-fit: сравнение эмпирического распределения с теоретическим

Ситуация: есть категории и частоты, хотим проверить "похоже ли на теорию".

- Есть наблюдаемые частоты O_i
- Есть ожидаемые частоты E_i
- Статистика:

$$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}$$

2) χ^2 на независимость (две категориальные переменные)

Ситуация: таблица сопряженности (contingency table). Проверяем:

- H_0 : признаки независимы
- H_1 : есть зависимость

требования для χ^2

- наблюдения независимы,
- ожидаемые частоты E_i не должны быть слишком маленькими (часто говорят "желательно ≥ 5 ").

2) Идея статистики z

В z-тесте всегда одна логика:

$$z = \frac{\text{оценка} - \text{значение по } H_0}{\text{стандартная ошибка}}$$

Гипотезы (двусторонний тест):

- $H_0: p_1 = p_2$
- $H_1: p_1 \neq p_2$

3.2 Формула статистики

Под H_0 объединяем долю (pooled):

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$$

Стандартная ошибка разности долей:

$$SE = \sqrt{\hat{p}(1-\hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

$$z = \frac{\hat{p}_1 - \hat{p}_2}{SE}$$

3.1 Что сравниваем

Есть две группы:

- в группе A: x_1 успехов из n_1 (например, покупок) И:
- в группе B: x_2 успехов из n_2

Доли:

$$\hat{p}_1 = \frac{x_1}{n_1}, \quad \hat{p}_2 = \frac{x_2}{n_2}$$

4) Z-тест для среднего (когда σ известна)

4.1 Постановка

- $H_0: \mu = \mu_0$
- $H_1: \mu \neq \mu_0$

Если σ известна, то:

$$z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$$

доверительный интервал:

Если мы строим 95% CI для разницы и:

- 0 НЕ входит в интервал $\rightarrow$ различие статистически значимо на $\alpha=0.05$
- 0 входит $\rightarrow$ на 0.05 значимости доказательств разницы нет

A/B-тест — это эксперимент, где пользователей случайно делят на группы:

- A (control / контроль) — текущая версия продукта
- B (test / тест) — версия с изменением (фича, новый дизайн, алгоритм)

Дальше сравнивают целевую метрику (конверсия, CTR, средний чек и т.д.). Цель — понять, вызвало ли изменение эффект, а не “нам просто повезло с сезоном/рекламой/праздниками”.

Группы должны отличаться только одним фактором — вашим изменением.

Шаблон хорошей гипотезы (как в лекции)

1. Предпосылка (что в данных не так / где проблема)
2. Возможность (какое изменение делаем)
3. Кого коснётся (аудитория)
4. Почему это должно сработать (механика/мотивация)
5. Ожидаемый эффект (желательно числом: +X% к метрике)

Дизайн эксперимента

1. Формулировку гипотезы + ожидаемый размер эффекта
2. Описание аудитории
3. Описание вариантов + размер групп
4. Метрики и ожидаемые исходы
5. Длительность теста
6. Итоги/результаты

Сплит-система — сервис/механизм, который назначает пользователю вариант A или B так, чтобы:

- распределение было случайным
- группы были стабильны во времени
- при множестве запусков “не ломалась” ошибка 1 рода

Нулевая и альтернативная гипотезы

- H0: эффекта нет (A и B одинаковы по целевой метрике)
- H1: эффект есть (есть отличие)

Мощность = 1 – β: шанс найти эффект

MDE (minimum detectable effect) — минимальный эффект, который имеет бизнес-смысл.

Тип метрики	Пример	Что сравниваем	Частые тесты
Доля / бинарная	конверсия, CTR	пропорции	z-тест для пропорций, χ^2
Среднее количественной	ARPU, средний чек, время	средние	t-test (если “похоже на норм.”), Mann-Whitney (если сильная асимметрия)
Сравнение распределений целиком	распределение чеков	форму распределения	KS-тест, bootstrap
Категориальные распределения	устройства/каналы	таблицы частот	χ^2 независимости