

Программирование на Python

Тема 7. Лекция 8
A/B-тестирования

Андрей Сусов
@and_us7

НИУ ВШЭ, 2025

Кейс Google: «41 оттенок синего»


- В 2009 году Google проверял 41 оттенок синего цвета для ссылок и рекламных элементов в поиске.
- Цель состояла в поиске варианта, который даст наибольшее количество кликов.
- Использовался метод A/B-тестирования, когда пользователей случайным образом делили на группы. Одна группа видела текущую версию (контрольная), а другая — с измененной версией, в данном случае, с другим оттенком синего (тестовая).

Кейс Google: «41 оттенок синего»

- В 2009 году Google проверял 41 оттенок синего цвета для ссылок и рекламных элементов в поиске.
- Цель состояла в поиске варианта, который даст наибольшее количество кликов.
- Использовался метод A/B-тестирования, когда пользователей случайным образом делили на группы. Одна группа видела текущую версию (контрольная), а другая — с измененной версией, в данном случае, с другим оттенком синего (тестовая).
- По оценкам Google, итоговая выгода составила **около \$200 млн в год** (за счет масштабирования на миллиарды показов).

Как проходят А/Б тесты?

Небольшая картинка:



Плюсы такого подхода

- Очень простая концепция - делим пользователей на 2 группы, над одной ставим эксперименты и смотрим на результаты.
- Эксперименты проходят на реальных пользователях.
- Используются научные методы для того, чтобы доказать неслучайность изменений.
- Фактически, A/B тесты объединяют в себе максимально интуитивно понятную концепцию и мощные статистические инструменты.
- Почему нельзя просто изменить цвет кнопки на любой другой для всех пользователей?

Плюсы такого подхода

- Очень простая концепция - делим пользователей на 2 группы, над одной ставим эксперименты и смотрим на результаты.
- Эксперименты проходят на реальных пользователях.
- Используются научные методы для того, чтобы доказать неслучайность изменений.
- Фактически, A/B тесты объединяют в себе максимально интуитивно понятную концепцию и мощные статистические инструменты.
- Почему нельзя просто изменить цвет кнопки на любой другой для всех пользователей?
- Даже если в следующем месяце продажи взлетят на 100%, то мы не будем уверены, как цвет кнопки повлиял на это? Возможно, со старым цветом взлет бы был на 200%.

С чего начинается эксперимент?

С чего начинается эксперимент?

Эксперимент начинается с гипотезы

- Гипотеза — это предположение, которое описывает феномен (факт, событие, явление, etc), и может быть проверено в ходе эксперимента.
- Важное отличие гипотезы от идеи заключается в том, что в основе гипотезы лежат наблюдения.
- Эксперимент - научный метод проверить эту гипотезу и найти потенциальные противоречия.

А зачем выпивать два литра воды в день, когда можно выпивать два литра пива?



Простите, но это не научный подход. Пиво состоит из воды лишь примерно на 90%, так что нужно выпивать около 2,22 литра пива в день. Берегите здоровье.

Формирование гипотезы

Хорошо сформулированная гипотеза:

1. Предпосылка

Аналитика показывает, что 40% посетителей онлайн-магазина мыла уходят с главной страницы, не переходя к товарам. Интервью с пользователями выявили, что они ищут экологичные продукты, но не видят такой информации сразу.

2. Возможность

Разработать и выделить на главной странице раздел для экологичных мыл.

3. Кого коснется

Пользователи, заинтересованные в экологичных продуктах.

4. Мотивация

Пользователи получат быстрый доступ к экологичным товарам, что упростит их выбор и покупку.

5. Эффект, который мы ожидаем

Увеличение конверсии с главной страницы на страницы товаров на 15%, снижение отказов на главной странице на 10%.

Плохо сформулированная гипотеза:

1. Предпосылка

Из отзывов пользователей мы узнали, что некоторые ищут более уникальные ароматы мыла.

2. Возможность

Расширить ассортимент, добавив экзотические ароматы мыла.

3. Кого коснется

Покупатели, заинтересованные в новинках и уникальных ароматах.

4. Мотивация

Пользователи, возможно, будут рады обновлению ассортимента и попробуют новые ароматы.

5. Эффект, который мы ожидаем

Увеличение интереса к новым товарам и, возможно, рост продаж.

Дизайн эксперимента

- Дизайн эксперимента - ключевая вещь, определяющая порядок проведения эксперимента.
- Чаще всего является не только фактическим инструментом, но и формальным документом для заведения эксперимента.
- Должен содержать в себе как минимум следующие вещи:

Дизайн эксперимента

- Дизайн эксперимента - ключевая вещь, определяющая порядок проведения эксперимента
- Чаще всего является не только фактическим инструментом, но и формальным документом для заведения эксперимента
- Должен содержать в себе как минимум следующие вещи:
 - 1. Формулировка гипотезы с сформулированным ожидаемым размером эффекта
 - 2. Описание аудитории
 - 3. Описание вариантов с размером каждой группы
 - 4. Ожидаемые исходы и метрики
 - 5. Продолжительность теста
 - 6. Результаты

Расшифровка основных метрик

ARPU

Average revenue per user - мера, показывающая средний доход на одного юзера

WAU

WAU - мера, показывающая количество уникальных юзеров в продукте за неделю

MAU

DAU - мера, показывающая количество уникальных юзеров в продукте за месяц

ARPPU

Average revenue per paying user - мера, показывающая средний доход на одного покупающего юзера

DAU

DAU - мера, показывающая количество уникальных юзеров в продукте за день

Retention

Retention - мера, показывающая, какая часть новых пользователей вернется в приложение в следующий период

Выбор контрольной и экспериментальной групп

- Контрольная и экспериментальная группы должны быть максимально похожи.
- Чтобы эффект изменения был честным, группы должны отличаться только одним фактором — вашей фицей / изменением интерфейса / алгоритмом.
- A/B-тест — это не про сравнение «А» и «В». Это про сравнение двух идентичных выборок, где единственное отличие — ваша гипотеза.
- Если группы не одинаковые, эксперимента не существует.
- Что бы вы могли назвать в качестве отличительных признаков?

Выбор контрольной и экспериментальной групп

- Контрольная и экспериментальная группы должны быть максимально похожи.
- Чтобы эффект изменения был честным, группы должны отличаться только одним фактором — вашей фицей / изменением интерфейса / алгоритмом.
- A/B-тест — это не про сравнение «А» и «В». Это про сравнение двух идентичных выборок, где единственное отличие — ваша гипотеза.
- Если группы не одинаковые, эксперимента не существует.
- Что бы вы могли назвать в качестве отличительных признаков?
 - Возраст
 - Пол
 - Девайсы
 - Время жизни в продукте
 - Количество покупок
 - Частота покупок
 - Средний чек
 - Конверсии

А как вообще сравнить, что две группы похожи?

Статистический тест

- Если рассуждать абстрактно, статистический тест - это способ получить ответ “да” или “нет” на некоторый вопрос сформулированный в виде гипотезы.
- Представим себе ситуацию, у нас есть стулья и в одном из них есть бриллианты. А также есть эксперт, который видел кучу стульев без бриллиантов. Мы приносим по очереди стулья и на основе каких-то своих критериев эксперт говорит: стул с бриллиантом или без.
- Давайте сформулируем нулевую и альтернативную гипотезы.

Статистический тест

- Если рассуждать абстрактно, статистический тест - это способ получить ответ “да” или “нет” на некоторый вопрос сформулированный в виде гипотезы.
- Представим себе ситуацию, у нас есть стулья и в одном из них есть бриллианты. А также есть эксперт, который видел кучу стульев без бриллиантов. Мы приносим по очереди стулья и на основе каких-то своих критериев эксперт говорит: стул с бриллиантом или без.
- H_0 : Стул без бриллианта
 H_1 : Стул с бриллиантом
- Нашим экспертом является некоторая статистика теста, которая “видела” много случаев, когда H_0 верна.

Статистический тест

Статистический тест - правило, по которому принимается решение о том принимать или не принимать нулевую гипотезу. Это правило строится на предположении о том, что статистика теста имеет некоторое распределение, если нулевая гипотеза верна. Разберемся на картинке:



Статистические основы принятия решений

- p -value - вероятность получить, такое или более экстремальное значение статистики при условии, что нулевая гипотеза верна.
- Ошибка первого рода — ситуация, когда ошибочно отвергнута нулевая гипотеза.
- Ошибка второго рода — ситуация, когда ошибочно не отвергнута нулевая гипотеза (фактически, когда она неверно принята).
- Мощность ($1 - \text{вер-ть ошибки второго рода}$). Показывает вероятность отвергнуть нулевую гипотезу, если она не верна.
- Чем вероятность ошибки первого рода отличается от p -value?
- В эксперименте важны 2 вещи: вероятность ошибки 1 рода и мощность.

Промежуточные итоги

Нужны две похожие группы

Чтобы понять группы похожи или нет нужно выбрать метрику

Статистический тест

Нужен, чтобы сравнить две группы между собой

У теста есть два параметра

Вер-ть ошибки первого рода и мощность

Как это применимо к гипотезам?

Мы не хотим краснеть перед начальством (type 1 error), но при этом хотим по максимуму находить рабочие гипотезы

Type I error

Фиксируем на приемлемом уровне для нас

Power

Стараемся максимизировать при таком уровне ошибки первого рода


Как сформировать две однородные группы?

Сплит-система

- **Сплит-система** — это сервис, который решает, какую версию продукта должен видеть конкретный пользователь, и обеспечивает честность эксперимента и однородность выборок.
- Хорошая сплит-система генерирует стабильные во времени одинаковые группы при бесконечном количестве разбиений (с точки зрения ошибки 1-ого рода).
- Берём ID пользователя → пропускаем через хэш-функцию → получаем большое случайное число → берём остаток деления на 100 → получаем число от 0 до 99. 0–49 → группа А (50%) 50–99 → группа В (50%)
- Сплит-система обеспечивает случайность распределения, а это в свою очередь приводит к однородности групп.

A/A тест

- **A/A тест** - Способ проверить, что сплит-система подбирает одинаковые группы
- Пусть сплит система на основе исторических данных выдала две группы. Если мы сравним их между собой - мы проведем A/A тест. Тест, где между двумя группами нет изменений (нулевая гипотеза верна).
- Если провести много-много таких тестов, то распределение будет равномерным и это значит, что сплит система работает правильно с точки зрения ошибки 1-ого рода.



Как сформировать две однородные группы?

- Если A/A тест выдает равномерное распределение значений p-value, то наша сплит-система работает хорошо! Можно брать 2 группы и переходить непосредственно к A/B тестированию!
- Но нет ли тут парадокса?

Как сформировать две однородные группы?

- Если A/A тест выдает равномерное распределение значений p-value, то наша сплит-система работает хорошо! Можно брать 2 группы и переходить непосредственно к A/B тестированию!
- Но нет ли тут парадокса?
- А если именно это разбиение попадет в 5% где $p\text{-value} < 0.05$? То есть гипотезу об идентичности выборок следует отклонить.

Как сформировать две однородные группы?

- Если A/A тест выдает равномерное распределение значений p-value, то наша сплит-система работает хорошо! Можно брать 2 группы и переходить непосредственно к A/B тестированию!
- Но нет ли тут парадокса?
- А если именно это разбиение попадет в 5% где $p\text{-value} < 0.05$? То есть гипотезу об идентичности выборок следует отклонить.
- Это абсолютно нормально! Потому что 5% — это ровно то, на что мы сами соглашаемся, выбирая **уровень значимости $\alpha = 0.05$** . Мы согласны, что в A/B тесте в 5% случаев мы получим ложное обнаружение эффекта, когда его нет.
- Это не ошибка! А Математическое свойство статистики.
p.s. AA/тест проводят либо на исторических данных либо в реальном времени.

Уже вот вот и запустим A/B-тест, но...

на какое время его запускать?

MDE - минимально-детектируемый эффект

- MDE — это не статистическая величина, а бизнес-решение.
- MDE = минимальный эффект, который имеет бизнес-смысл. Если эффект меньше — нам всё равно, это не меняет решения.
- Этот эффект определяет RO/PM продукта.

Необходимое количество наблюдений (sample size)

- MDE — это не статистическая величина, а бизнес-решение.
- MDE = минимальный эффект, который имеет бизнес-смысл. Если эффект меньше — нам всё равно, это не меняет решения.
- Этот эффект определяет PO/PM продукта.
- Формулу для размер выборки обычно определяют так:

$$N = 2 \left(\frac{z_{1-\alpha} + z_{1-\beta}}{\text{MDE}} \right)^2 S^2$$

Необходимое количество наблюдений (sample size)

- MDE — это не статистическая величина, а бизнес-решение.
- MDE = минимальный эффект, который имеет бизнес-смысл. Если эффект меньше — нам всё равно, это не меняет решения.
- Этот эффект определяет PO/PM продукта.
- Формулу для размер выборки обычно определяют так:

$$N = 2 \left(\frac{z_{1-\alpha} + z_{1-\beta}}{\text{MDE}} \right)^2 S^2$$

Прошу сильно не переживать,
формула для ознакомления

- Но на практике она выглядит так:

$$N = 2 \left(\frac{z_{1-\alpha} + z_{1-\beta}}{\text{MDE}} \right)^2 \cdot S^2(T), \text{ где } S^2(T) - \text{функция оценки дисперсии}$$

Длительность теста

$$\text{Длительность} = \frac{\text{Необходимое } N}{\text{Суточный трафик на группу}}$$

- В любом случае A/B тест не стоит запускать менее, чем на неделю, так как существует такой феномен как недельный цикл.
- Размер самих выборок определяется из целей бизнеса

Важно: количество наблюдений != количество человек в группе

Мы сформировали и посчитали все, что нужно для
запуска A/B теста!!!

Запускаем и анализируем результаты!

Выбор статистического критерия

- Метрика — доля / бинарная (конверсия, CTR, доля пользователей, купивших товар)
→ Используй **z-тест для пропорций** или **χ^2 -тест**.
- Метрика — среднее значение количественной переменной (средний чек, ARPU, время на сайте)
→ Используй **t-тест**, если распределение примерно нормальное, или **Mann-Whitney U-тест**, если распределение сильно перекошено.
- Метрика — сравнение распределений целиком (например, распределение чеков, времени, глубины просмотра)
→ Используй **тест Колмогорова-Смирнова** или методы бутстрапа.
- Метрика — категориальные переменные (распределение по устройствам, каналам, типам пользователей)
→ Используй **χ^2 -тест независимости**.

Анализ результатов

Ситуация	Что увидели	Рекомендация
Статистически значимый положительный эффект		
Статистически значимый, но эффект < MDE		
Не статистически значимый		
Статистически значимый отрицательный эффект		

Анализ результатов

Ситуация	Что увидели	Рекомендация
Статистически значимый положительный эффект	$p\text{-value} < \alpha$, $\text{uplift} \geq \text{MDE}$	
Статистически значимый, но эффект $< \text{MDE}$		
Не статистически значимый		
Статистически значимый отрицательный эффект		

Анализ результатов

Ситуация	Что увидели	Рекомендация
Статистически значимый положительный эффект	$p\text{-value} < \alpha$, $\text{uplift} \geq \text{MDE}$	Внедряем изменение на всех пользователей. Проверяем guard-rail метрики (ошибки, отказ, нагрузка).
Статистически значимый, но эффект < MDE		
Не статистически значимый		
Статистически значимый отрицательный эффект		

Анализ результатов

Ситуация	Что увидели	Рекомендация
Статистически значимый положительный эффект	$p\text{-value} < \alpha$, $\text{uplift} \geq \text{MDE}$	Внедряем изменение на всех пользователей. Проверяем guard-rail метрики (ошибки, отказ, нагрузка).
Статистически значимый, но эффект $< \text{MDE}$	$p\text{-value} < \alpha$, $\text{uplift} < \text{MDE}$	Размышляем: хоть и есть эффект — он слаб. Решаем: стоит ли внедрять с учётом ресурсов.
Не статистически значимый		
Статистически значимый отрицательный эффект		

Анализ результатов

Ситуация	Что увидели	Рекомендация
Статистически значимый положительный эффект	$p\text{-value} < \alpha$, $\text{uplift} \geq \text{MDE}$	Внедряем изменение на всех пользователей. Проверяем guard-rail метрики (ошибки, отказ, нагрузка).
Статистически значимый, но эффект $< \text{MDE}$	$p\text{-value} < \alpha$, $\text{uplift} < \text{MDE}$	Размышляем: хоть и есть эффект — он слаб. Решаем: стоит ли внедрять с учётом ресурсов.
Не статистически значимый	$p\text{-value} \geq \alpha$	Нет уверенности. Возможные шаги: увеличить выборку/длительность или закрыть тест и запланировать новую гипотезу.
Статистически значимый отрицательный эффект		

Анализ результатов

Ситуация	Что увидели	Рекомендация
Статистически значимый положительный эффект	$p\text{-value} < \alpha$, $\text{uplift} \geq \text{MDE}$	Внедряем изменение на всех пользователей. Проверяем guard-rail метрики (ошибки, отказ, нагрузка).
Статистически значимый, но эффект $< \text{MDE}$	$p\text{-value} < \alpha$, $\text{uplift} < \text{MDE}$	Размышляем: хоть и есть эффект — он слаб. Решаем: стоит ли внедрять с учётом ресурсов.
Не статистически значимый	$p\text{-value} \geq \alpha$	Нет уверенности. Возможные шаги: увеличить выборку/длительность или закрыть тест и запланировать новую гипотезу.
Статистически значимый отрицательный эффект	$p\text{-value} < \alpha$, эффект хуже, чем у контрольной группы	Откатываем изменение. Анализируем: баги, сегменты, неожиданные побочные эффекты.

Впереди - огромные просторы для изучения

- Прокси-метрики и композиции метрик
- Методы снижения дисперсии (CUPED / CUPAC и тд)
- A/B/n и многомерные эксперименты
- Проблемы масштабных сплитов
- Линеаризация - поюзерная прокси-метрика
- Подход к оценке A/B теста через доверительный интервал!!!
- И много чего другого...

Пришло время для ваших вопросов

надеюсь, время еще есть