

Программирование на Python

Тема 5. Лекция 6


Классическое машинное обучение. Обучение с учителем

Юрий Саночкин


ysanochkin@hse.ru

НИУ ВШЭ, 2025

Какие бывают задачи анализа данных?



Какие бывают задачи анализа данных?



Теперь мы, наконец, немного
посмотрим этот раздел


Машинное обучение

Машинное обучение

- Как бы вы сформулировали, что такое машинное обучение в целом? Как вы это понимаете?

Машинное обучение


Наука о поиске
закономерностей в данных
с помощью компьютера и
математики



Машинное обучение

- На какие два больших блока можно разделить задачи классического машинного обучения?

Классическое Обучение



Классическое Обучение




Машинное обучение

- Данные блоки задач машинного обучения неразрывно связаны с понятием размеченных/неразмеченных данных

Машинное обучение

- Данные блоки задач машинного обучения неразрывно связаны с понятием размеченных/неразмеченных данных
- Что такое размеченные/неразмеченные данные?
- Приведите примеры размеченных/неразмеченных данных

Размеченные (labelled) vs неразмеченные (unlabelled) данные



Размеченные (labelled) vs неразмеченные (unlabelled) данные

ID	Clump	UnifSize	UnifShape	MargAdh	SingEpiSize	BareNuc	BlandChrom	NormNucl	Mit	Class
1000025	5	1	1	1	2	1	3	1	1	benign
1002945	5	4	4	5	7	10	3	2	1	benign
1015425	3	1	1	1	2	2	3	1	1	malignant
1016277	6	8	8	1	3	4	3	7	1	benign
1017023	4	1	1	3	2	1	3	1	1	benign
1017122	8	10	10	8	7	10		7	1	malignant
1018099	1	1	1	1	2	10	3	1	1	benign
1018561	2	1	2	H	2	1	3	1	1	benign
1033078	2	1	1	1	2	1	1	1	5	benign
1033078	4	2	1	1	2	1	2	1	1	benign

labels

Customer Id	Age	Edu	Years Employed	Income	Card Debt	Other Debt	Address	DebtIncomeRatio
1	41	2		6	19	0.124	1.073 NBA001	6.3
2	47	1		26	100	4.582	8.218 NBA021	12.8
3	33	2		10	57	6.111	5.802 NBA013	20.9
4	29	2		4	19	0.681	0.516 NBA009	6.3
5	47	1		31	253	9.308	8.908 NBA008	7.2
6	40	1		23	81	0.998	7.831 NBA016	10.9
7	38	2		4	56	0.442	0.454 NBA013	1.6
8	42	3		0	64	0.279	3.945 NBA009	6.6
9	26	1		5	18	0.575	2.215 NBA006	15.5
10	47	3		23	115	0.653	3.947 NBA011	4
11	44	3		8	88	0.285	5.083 NBA010	6.1
12	34	2		9	40	0.374	0.266 NBA003	1.6

unlabeled

Машинное обучение

- Сегодня мы с вами обсудим механику процесса обучения на примере трёх главных задач классического ML: регрессии, классификации, кластеризации

Машинное обучение

- Сегодня мы с вами обсудим механику процесса обучения на примере трёх главных задач классического ML: регрессии, классификации, кластеризации
- ...а также разберем метрические алгоритмы, рассмотрим нашу первую модель машинного обучения — KNN — и обсудим еще много важных сопутствующих концепций!
- Короче говоря, будет интересно! Поехали! :)

Машинное обучение

- В начале очень быстро, чтобы испугаться

Машинное обучение


- В начале очень быстро, чтобы испугаться

...но позже разобраться и
понять, что это совершенно
не страшно :)

Машинное обучение


- В начале очень быстро, чтобы испугаться:

Регрессия




$Y \subseteq \mathbb{R}$. Нужно восстановить
обычную функциональную
зависимость $f: X \rightarrow Y$

Классификация



$Y \subseteq [0, 1]^n$. Нужно предсказать
распределение вероятностей на
возможных вариантах

Кластеризация




Нужно предъявить такие классы
эквивалентности, чтобы объекты одного
класса были более похожи друг на друга,
чем объекты разных классов

Машинное обучение


Задачи обучения с учителем
(supervised learning)

Регрессия




$Y \subseteq \mathbb{R}$. Нужно восстановить
обычную функциональную
зависимость $f: X \rightarrow Y$

Классификация



$Y \subseteq [0, 1]^n$. Нужно предсказать
распределение вероятностей на
возможных вариантах

Кластеризация




Нужно предъявить такие классы
эквивалентности, чтобы объекты одного
класса были более похожи друг на друга,
чем объекты разных классов

Машинное обучение


Задачи обучения без учителя
(unsupervised learning)

Регрессия




$Y \subseteq \mathbb{R}$. Нужно восстановить
обычную функциональную
зависимость $f: X \rightarrow Y$

Классификация



$Y \subseteq [0, 1]^n$. Нужно предсказать
распределение вероятностей на
возможных вариантах

Кластеризация



Нужно предъявить такие классы
эквивалентности, чтобы объекты одного
класса были более похожи друг на друга,
чем объекты разных классов

Обучение с учителем

Обучение с учителем

- Итак, вспомним основные обозначения!
- X — множество всех объектов в пространстве признаков
- Y — область значений целевой переменной

Обучение с учителем

- Итак, вспомним основные обозначения!
- X — множество всех объектов в пространстве признаков
- Y — область значений целевой переменной
- Что представляет собой машинное обучение в этих терминах?

Обучение с учителем

- Итак, вспомним основные обозначения!
- X — множество всех объектов в пространстве признаков
- Y — область значений целевой переменной
- Что представляет собой машинное обучение в этих терминах?
- Фактически это про поиск неизвестной зависимости:
- $f: X \rightarrow Y$ — неизвестная закономерность, функция

Обучение с учителем

- Итак, вспомним основные обозначения!
- X — множество всех объектов в пространстве признаков
- Y — область значений целевой переменной
- Что представляет собой машинное обучение в этих терминах?
- Фактически это про поиск неизвестной зависимости:
- $f: X \rightarrow Y$ — неизвестная закономерность, функция
- Может даже иметь стохастическую природу!

Обучение с учителем

- Как мы это осуществляем?

Обучение с учителем


- Как мы это осуществляем?
- Дано: Обучающая выборка вида $\{(X_i, y_i)\}_{i=1}^n$

Обучение с учителем

- Как мы это осуществляем?
- Дано: Обучающая выборка вида $\{(X_i, y_i)\}_{i=1}^n$
- Цель: Максимально точно определить и приблизить f .

Обучение с учителем

- Как мы это осуществляем?
- Дано: Обучающая выборка вида $\{(X_i, y_i)\}_{i=1}^n$
- Цель: Максимально точно определить и приблизить f .



Обучение без учителя

Обучение без учителя

- В противоположность задачам supervised learning, в классических задачах unsupervised learning — есть X , но нет обучающей выборки (т.е. мы не знаем правильные ответы).

Обучение без учителя

- В противоположность задачам supervised learning, в классических задачах unsupervised learning — есть X , но нет обучающей выборки (т.е. мы не знаем правильные ответы).
- В таких задачах обычно минимизируют “энтропию” системы: ищут наиболее удачную расстановку меток.

Задача регрессии

Задача регрессии

- Что такое задача регрессии?

Задача регрессии

- Что такое задача регрессии?
- Говоря по простому — задача, где мы хотим предсказать некоторое численное (вещественное) значение



Задача регрессии

- Что такое задача регрессии?
- Говоря по простому — задача, где мы хотим предсказать некоторое численное (вещественное) значение
- Регрессия относится к supervised learning (обучение с учителем).
- Приведите примеры каких-нибудь задач регрессии

Задача регрессии

- Что такое задача регрессии?
- Говоря по простому — задача, где мы хотим предсказать некоторое численное (вещественное) значение
- Регрессия относится к supervised learning (обучение с учителем).
- Приведите примеры каких-нибудь задач регрессии
 - Предсказание стоимости жилья для риэлторской компании
 - Предсказание времени доставки
 - Предсказание спроса на такси в конкретном районе в конкретный час завтрашнего дня
 - И так далее

Задача регрессии



Задача классификации

Задача классификации

- Что такое задача классификации?

Задача классификации

- Что такое задача классификации?
- Говоря по простому — задача, где мы хотим предсказать принадлежность объекта к одному из заранее определенных классов (категорий)



Задача классификации

- Что такое задача классификации?
- Говоря по простому — задача, где мы хотим предсказать принадлежность объекта к одному из заранее определенных классов (категорий)
- Классификация — так же, как и регрессия, — относится к supervised learning (обучение с учителем).
- Приведите примеры каких-нибудь задач классификации

Задача классификации

- Что такое задача классификации?
- Говоря по простому — задача, где мы хотим предсказать принадлежность объекта к одному из заранее определенных классов (категорий)
- Классификация — так же, как и регрессия, — относится к supervised learning (обучение с учителем).
- Приведите примеры каких-нибудь задач классификации
 - Предсказание оттока клиентов/сотрудников на основе их поведения
 - Классификация клеток ткани на здоровые и опухолевые
 - Определение типа съедобности гриба по его характеристикам
 - И так далее

Задача классификации



Задача кластеризации

Задача кластеризации

- Что такое задача кластеризации?

Задача кластеризации

- Что такое задача кластеризации?
- Говоря по простому — задача, где мы хотим разделить наши объекты на группы (сегменты), заранее не зная критерии и принципы разделения, но при этом так, чтобы объекты в группах были максимально похожи между собой


Задача кластеризации

- Кластеризация, в отличие от двух предыдущих, относится к unsupervised learning (обучение без учителя).
- Приведите примеры каких-нибудь задач кластеризации

Задача кластеризации

- Кластеризация, в отличие от двух предыдущих, относится к unsupervised learning (обучение без учителя).
- Приведите примеры каких-нибудь задач кластеризации
 - Сегментация аудитории для таргетированной рекламы
 - Идентификация типов клеток в образце данных секвенирования
 - Поиск сообществ в социальном графе (из соцсети или из инсайдерской информации о структуре организации)
 - Задача разделения смеси распределений
 - И так далее

Задача кластеризации



Метрические алгоритмы

Метрические алгоритмы


- Что такое метрические алгоритмы?

Метрические алгоритмы

- Что такое метрические алгоритмы?
- Метрическими алгоритмами в машинном обучении называются алгоритмы, основанные на вычислении оценок сходства между объектами (путём расчёта какой-либо метрики)

Метрические алгоритмы

- Что такое метрические алгоритмы?
- Метрическими алгоритмами в машинном обучении называются алгоритмы, основанные на вычислении оценок сходства между объектами (путём расчёта какой-либо метрики)



Метрические алгоритмы

- Существует большое количество различных метрических алгоритмов, а также множество нюансов касательно метрик, используемых в них.
- Мы с вами сейчас не будем погружаться в нюансы всего устройства этих вещей — а вместо этого рассмотрим идею одного из самых простых и вместе с тем классических алгоритмов машинного обучения — алгоритма KNN. Данный алгоритм является ярким представителем класса метрических алгоритмов, которые нас сейчас как раз и интересуют.

Алгоритм KNN

KNN — это пример
«ленивого», а также
непараметрического алгоритма
машинного обучения

Алгоритм KNN

KNN — это пример
«ленивого», а также
непараметрического алгоритма
машинного обучения

Что означают эти страшные слова — мы узнаем
немного позже :)

Алгоритм KNN

- Идея алгоритма заключается в следующем:

Алгоритм KNN

- Идея алгоритма заключается в следующем:
- На вход подается вектор — признаковое описание какого-то объекта

Алгоритм KNN

- Идея алгоритма заключается в следующем:
- На вход подается вектор — признаковое описание какого-то объекта
- Находится K ближайших к нему векторов, для которых ответ известен

Алгоритм KNN

- Идея алгоритма заключается в следующем:
- На вход подается вектор — признаковое описание какого-то объекта
- Находится K ближайших к нему векторов, для которых ответ известен

На самом деле, что означает «ближайших» — в этом и есть основная соль... Но мы этот вопрос пока что опустим :)



Алгоритм KNN

- Идея алгоритма заключается в следующем:
- На вход подается вектор — признаковое описание какого-то объекта
- Находится K ближайших к нему векторов, для которых ответ известен
- Ответ для нового объекта выбирается с помощью:
 - Усреднения, в случае регрессии
 - Голосования, в случае классификации


Алгоритм KNN

- Идея алгоритма заключается в следующем:
- На вход подается вектор — признаковое описание какого-то объекта
- Находится K ближайших к нему векторов, для которых ответ известен
- Ответ для нового объекта выбирается с помощью:
 - Усреднения, в случае регрессии
 - Голосования, в случае классификации
- Возможно также усреднение/голосование с весами и многие другие модификации стандартного алгоритма


Алгоритм KNN





Алгоритм KNN




Вопрос — а откуда взялось число 3, и вообще как выбирается значение K в KNN?





Алгоритм KNN





Алгоритм KNN



Алгоритм KNN



Алгоритм KNN



А почему третьим ближайшим оказался фиолетовый, а не еще один красный?

Алгоритм KNN

- Сейчас мы с вами опустим подробности реализации KNN — для нас было важно понять интуицию, которая стоит за этим алгоритмом.

Алгоритм KNN

- Сейчас мы с вами опустим подробности реализации KNN — для нас было важно понять интуицию, которая стоит за этим алгоритмом.
- Впоследствии эта интуиция пригодится нам во всех метрических алгоритмах!

Обучение ML-алгоритмов

Обучение ML-алгоритмов

- В задачах supervised learning принято делить выборку на три непересекающиеся части.
- Что это за части?

Обучение ML-алгоритмов

- В задачах supervised learning принято делить выборку на три непересекающиеся части.
- Что это за части?
- Обучающая выборка (training sample)
 - На ней происходит обучение модели

Обучение ML-алгоритмов

- В задачах supervised learning принято делить выборку на три непересекающиеся части.
- Что это за части?
- Обучающая выборка (training sample)
 - На ней происходит обучение модели
- Валидационная выборка (validation sample)
 - На ней считают метрики качества, а по ним уже подбирают оптимальные гиперпараметры

Обучение ML-алгоритмов


- В задачах supervised learning принято делить выборку на три непересекающиеся части.
- Что это за части?
- Обучающая выборка (training sample)
 - На ней происходит обучение модели
- Валидационная выборка (validation sample)
 - На ней считают метрики качества, а по ним уже подбирают оптимальные гиперпараметры

Что еще за метрики качества и гиперпараметры —
мы с вами обсудим позднее

Обучение ML-алгоритмов


- В задачах supervised learning принято делить выборку на три непересекающиеся части.
- Что это за части?
- Обучающая выборка (training sample)
 - На ней происходит обучение модели
- Валидационная выборка (validation sample)
 - На ней считают метрики качества, а по ним уже подбирают оптимальные гиперпараметры
- Тестовая выборка (test sample)
 - По ней непосредственно оценивают качество обученной модели

Обучение ML-алгоритмов




- На самом деле, валидационную выборку используют не всегда.

Обучение ML-алгоритмов



- На самом деле, валидационную выборку используют не всегда.
- Когда используют — стараются брать её того же размера, что и тестовую.


Обучение ML-алгоритмов



- Важно! Каждая выборка должна быть репрезентативна!

Отложенная выборка

- Как один из вариантов, можно “отложить”, скажем, 20% обучающей выборки для валидации модели.
- Иными словами, использовать 80% выборки для обучения и 20% для тестирования.



Отложенная выборка

- Как один из вариантов, можно “отложить”, скажем, 20% обучающей выборки для валидации модели.
- Иными словами, использовать 80% выборки для обучения и 20% для тестирования.
- Если же хочется оценить качество алгоритма совсем честно и есть доступные ресурсы — можно посчитать метрики по кросс-валидации!

Кросс-валидация

- Что такое кросс-валидация? Как вы это понимаете?

Кросс-валидация

- Что такое кросс-валидация? Как вы это понимаете?
- Кросс-валидация — это подход по разделению данных на тренировочные и валидационные с помощью определенного алгоритма.

Кросс-валидация

- Что такое кросс-валидация? Как вы это понимаете?
- Кросс-валидация — это подход по разделению данных на тренировочные и валидационные с помощью определенного алгоритма.
- Идея кросс-валидации в следующем:
 - Разбиваем выборку на k частей

Кросс-валидация

- Что такое кросс-валидация? Как вы это понимаете?
- Кросс-валидация — это подход по разделению данных на тренировочные и валидационные с помощью определенного алгоритма.
- Идея кросс-валидации в следующем:
 - Разбиваем выборку на k частей
 - Из полученных k частей, $k - 1$ часть используются для обучения и одна — для тестирования (валидации)


Кросс-валидация

- Что такое кросс-валидация? Как вы это понимаете?
- Кросс-валидация — это подход по разделению данных на тренировочные и валидационные с помощью определенного алгоритма.
- Идея кросс-валидации в следующем:
 - Разбиваем выборку на k частей
 - Из полученных k частей, $k - 1$ часть используются для обучения и одна — для тестирования (валидации)
 - Процесс повторяется k раз. Каждый раз для тестирования выбирается разная часть

Кросс-валидация

- Что такое кросс-валидация? Как вы это понимаете?
- Кросс-валидация — это подход по разделению данных на тренировочные и валидационные с помощью определенного алгоритма.
- Идея кросс-валидации в следующем:
 - Разбиваем выборку на k частей
 - Из полученных k частей, $k - 1$ часть используются для обучения и одна — для тестирования (валидации)
 - Процесс повторяется k раз. Каждый раз для тестирования выбирается разная часть
 - Результаты тестирования усредняются

Кросс-валидация



Кросс-валидация

- Кросс-валидация — мощный инструмент и важный этап процесса обучения ML-алгоритмов.
- Плюсы:
 - Погрешность оценки уменьшается, т.к. используется весь набор
 - Качество модели улучшается и можно подобрать оптимальные гиперпараметры алгоритма
- Минусы:
 - Обучение производится k раз. Для некоторых моделей это может быть очень долго