

Программирование на Python

Тема 6. Лекция 7

Математическая статистика в анализе данных

Юрий Саночкин

ysanochkin@hse.ru

НИУ ВШЭ, 2025

Теория вероятностей и математическая статистика

- Теория вероятностей и математическая статистика — хорошо нам знакомый и важнейший раздел математической науки с точки зрения моделирования различных процессов и систем.
- Но так ли он важен в задачах анализа данных?
- Учитывая название нашей лекции — вопрос как будто бы риторический! 😊
- Практических приложений очень много; прямо сейчас обсудим два очень важных; а для этого в начале кое-что вспомним и повторим из предыдущего и частично будущего материала.


Временные ряды. Напоминание

- Конечно же, важнейшим приложением являются временные ряды.
- Давайте вспомним, что такой временной ряд?
- В анализе данных временной ряд — это данные, имеющие какую-либо временную отметку с постоянной частотой дискретизации.
- Приведите примеры любых временных рядов:

Временные ряды. Напоминание

- Цена курса доллара по дням
- Количество заболевших коронавирусом по месяцам
- Текущая цена криптовалюты по минутам
- Количество ретвитов в твиттер-аккаунте Трампа по дням
- Среднесуточное количество осадков на Манхэттене с 2014 по 2024 год по месяцам
- ...

Временные ряды. Напоминание



Временные ряды в математике

- Рассмотренные выше примеры, рассуждения и даже определение справедливы в рамках задачи анализа данных.
- А что представляют собой временные ряды как математический объект?
- Как ни странно, определение отличается незначительно.
- Временной ряд — это статистические данные, проиндексированные некоторыми временными отметками.
- А раз временной ряд — это статистические данные, значит так же, как и для любых статистических данных, для него существует истинное (теоретическое) распределение.

Временные ряды в математике


- Рассмотренные выше примеры, рассуждения и даже определение справедливы в рамках задачи анализа данных.
- А что представляют собой временные ряды как математический объект?
- Как ни странно, определение отличается незначительно.
- Временной ряд — это статистические данные, проиндексированные некоторыми временными отметками.
- А раз временной ряд — это статистические данные, значит так же, как и для любых статистических данных, для него существует ***истинное (теоретическое) распределение.***

Какие-то знакомые слова
нам тут встретились 😊

Машинное обучение

- Другим важным приложением теории вероятностей и математической статистики в анализе данных является статистическое обоснование моделей машинного обучения.
- Мы ещё будем в дальнейшем подробно говорить про задачи классического машинного обучения — однако пока что давайте посмотрим на это на пальцах и в основном как раз со статистической перспективы.
- Какие модели классического обучения с учителем вы знаете?
- Моделей существует действительно много; мы же со своей стороны сфокусируемся сейчас на одной из самых наглядных — линейной регрессии.

Аналитик и линейная регрессия



Линейная регрессия

- Как мы помним из обозначений, рассматривавшихся ранее, матрица $A_{k \times d}$, в которой каждая строка — это вектор одного из объектов, — раскладывается на матрицу объектов-признаков X и вектор целевой переменной y .
- Машинное обучение — это про предсказание неизвестной целевой переменной y по известной матрице X , при условии что до этого имелось некоторое количество (тренировочных) объектов, для которых были известны и признаки, и значения целевой переменной.

Линейная регрессия

- Как же такое предсказание делает линейная регрессия?
- Вот так:

$$\hat{y} = \langle \bar{x}, \bar{w} \rangle$$

$$\hat{y} = w_0 + \overset{\text{или}}{\sum_{i=1}^{d-1} x_i w_i}$$

Линейная регрессия

- Как же такое предсказание делает линейная регрессия?
- Вот так:

$$\hat{y} = \langle \bar{x}, \bar{w} \rangle$$


$$\hat{y} = w_0 + \sum_{i=1}^{d-1} x_i w_i$$

- Что же такое $\bar{w}$?
- Это вектор весов со значениями, соответствующими каждому признаку матрицы X ; и этот вектор определяется моделью линейной регрессии как раз на этапе обучения.

Линейная регрессия

- Но что если взглянуть на эту формулу немного с другой перспективы?

$$\hat{y} = w_0 + \sum_{i=1}^{d-1} x_i w_i$$

- Что такое x_i с точки зрения математики? Это некоторое измеримое случайное значение признака, характеризующее наш объект. 
- Что такое w_i с точки зрения математики? Это некоторое число. Константа. 
- Да, пусть изначально w_i нам и неизвестно — но ведь после обучения оно уже найдено, и теперь это просто константа.

Линейная регрессия


- Тогда что же такое $\hat{y}$ с этой точки зрения?

$$\hat{y} = w_0 + \sum_{i=1}^{d-1} x_i w_i$$

- Линейная комбинация случайных величин
- То есть тоже случайная величина!
- И работать мы с этим $\hat{y}$ можем именно в такой постановке. Используя весь имеющийся у нас математический аппарат.

Теория вероятностей и математическая статистика

- И снова — краткое напоминание основных понятий, терминов и блоков, которые понадобятся нам из теории вероятностей и математической статистики. Если что-то забыли и чувствуете себя неуверенно — лучше повторите потом всё сами ещё раз отдельно.




Базовые понятия

- Случайная величина — в теории вероятностей, величина, принимающая в зависимости от случая те или иные значения с определёнными вероятностями.
- Говоря более простым языком, любая измеримая величина, на которую воздействует какой-то элемент случайности.
 - Примером случайной величины может служить число, выпавшее на игральном кубике при случайном броске; или расстояние от точки падения снаряда до цели; или доход случайно взятого человека; или любой другой пример измеримой величины, на которую действует что-то случайное.

Базовые понятия


- Законом распределения (или просто распределением) случайной величины X называют правило, позволяющее находить вероятность попадания значений X в любой заданный числовой промежуток.
- Говоря более простым языком, распределение полностью характеризует случайный процесс, с которым мы работаем.
 - Всевозможные характеристики: матожидание, дисперсию, ...; график плотности, график распределения, квантили, ... — в общем, всё, что может как-то описать наш процесс, — вот всё это и задаёт распределение случайной величины.

Распределения



Непрерывные

- Нормальный закон распределения (закон Гаусса)
- Логарифмически нормальное распределение
- Гамма-распределение
- Экспоненциальный закон распределения




Дискретные

- Распределение Пуассона
- Геометрическое распределение
- Биномиальное распределение
- Бернулли

И, конечно, многие другие!


Распределения



Нормальное



Равномерное



Логнормальное




Гамма-распределение




Экспоненциальное




Вейбулла



Биномальное




Пуассона



Геометрическое


Функция распределения

- Функцией распределения случайной величины X называется функция $F(x)$, выражающая для каждого x вероятность того, что случайная величина X примет значение, меньшее x .



Функция плотности


- Функцией плотности (плотностью распределения или просто плотностью) $f(x)$ непрерывной случайной величины X называется производная ее функции распределения.



Функция плотности

- Один из главных способов задания распределения случайной величины. Может быть получена аппроксимацией из гистограммы.
- График плотности $f(x)$ называется кривой распределения.


Вероятность попадания случайной величины в интервал $[a,b]$:




$$P(a \leq X \leq b) = \int_a^b f(x) dx = F(b) - F(a)$$

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$


Распределение Бернулли




Равномерное распределение



Нормальное распределение



Нормальное распределение



Зеленой линией
обозначено стандартное
нормальное
распределение

Нормальное распределение

- Нормальное распределение отличается от других распределений своей особой природой.
- Физическая величина подчиняется нормальному распределению, когда она подвержена влиянию огромного числа одинаковых случайных помех.

Нормальное распределение

- Нормальное распределение может быть получено с использованием следующей формулы:

$$y = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x - \mu)^2}{2\sigma^2}}$$

μ = Mean

σ = Standard Deviation

$\pi \approx 3.14159 \dots$

$e \approx 2.71828 \dots$

Нормальное распределение

- Нормальное распределение может быть получено с использованием следующей формулы:

$$y = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x - \mu)^2}{2\sigma^2}}$$

μ = Mean

σ = Standard Deviation

$\pi \approx 3.14159 \dots$

$e \approx 2.71828 \dots$

- Алгоритмы ML, которым необходимо нормальное распределение признаков:
 - Наивный Байесовский классификатор
 - Модели на основе МНК
 - Квадратичный дискриминантный анализ
 - Линейный дискриминантный анализ
 - И многие другие

Распределения

- Важный вопрос про распределения, который понадобится нам в будущем.
- Можем ли мы сами сходу придумать какое-нибудь распределение? Или все известные распределения уже изучены и описаны?
- Конечно же, можем. Существует в принципе бесконечное число распределений, так как самым простым примером создания нового распределения является комбинация двух и более уже имеющихся (например, сумма)

Распределения

- Важный вопрос про распределения, который понадобится нам в будущем.
- Можем ли мы сами сходу придумать какое-нибудь распределение? Или все известные распределения уже изучены и описаны?
- Можно также придумать любую свою функцию, для которой будет справедливо, что

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$

И такая функция уже создаст свое новое распределение!

Распределения

- Важный вопрос про распределения, который понадобится нам в будущем.
- Можем ли мы сами сходу придумать какое-нибудь распределение? Или все известные распределения уже изучены и описаны?
- Можно также придумать любую свою функцию, для которой будет справедливо, что

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$

Кстати, зачем нужно это условие?


И такая функция уже создаст свое новое распределение!

Работа с временными рядами

- Теперь вернемся к нашему примеру с временными рядами.
- Какова вообще основная цель анализа временных рядов? То есть что мы хотим уметь с временными рядами делать?
- Наша главная цель — хотим уметь предсказывать последующие (будущие) значения по предыдущим (прошлым, уже имеющимся).
- Это и называется прогнозированием временных рядов.
- Анализ временного ряда — причём в первую очередь с математической точки зрения — это соответственно то, что поможет нам осуществить данное прогнозирование.

Прогнозирование временных рядов

- Говоря проще на языке анализа данных: мы хотим, чтобы программа по черной линии прошлого достроила для нас синюю линию будущего, указав при этом серым цветом статистическую погрешность



Сравнение распределений

- Рассмотрим два примера, представляющих собой разные эксперименты в области маркетинга.
- В эксперименте А двумстам пользователям показывают старый макет сайта, с целью определить конверсию в клики, причем вероятность клика у каждого пользователя независима и равна 0.2.
- В эксперименте В двумстам пятидесяти пользователям показывают измененный дизайн сайта, причем вероятность клика независима и равна 0.25.
- Вопрос: что это будут за распределения?

Сравнение распределений

- И в эксперименте А, и в эксперименте В, мы имеем дело с биномиальным распределением (если это неочевидно, читаем про него и вспоминаем после лекции).
- Но правда ли, что в таком случае в обоих экспериментах случайные величины распределены одинаково?
- Конечно же, нет! В распределениях есть различия — причем, довольно существенные с точки зрения бизнеса!
- Все дело в том, что:

$$A \sim Bi(200, 0.2)$$

$$B \sim Bi(250, 0.25)$$


Это разные распределения! У них только названия одинаковые!

Параметры распределения

- Что такое параметры распределения?
- Как и любые другие параметры в целом, — это численные величины, характеризующие особенности поведения величины, к которой они относятся
- Конкретно в случае с распределениями — параметры конкретизируют и наделяют смыслом распределения, которые сами по себе скорее представляют шаблоны поведения модели, нежели конкретную модель
- Величины, имеющие одинаковое распределение, но с разными параметрами, могут вести себя совершенно по-разному!

Параметры распределения

- Величины, имеющие одинаковое распределение, но с разными параметрами, могут вести себя совершенно по-разному!



Параметры распределения

- Какой прикладной смысл имеют параметры распределения?
- У некоторых распределений параметры легко интерпретируемы:
 - Например, у биномиального распределения есть 2 параметра: n и p , где n – количество экспериментов, p – вероятность успеха в 1 эксперименте;
 - У нормального распределения также 2 параметра: μ и σ , где μ – ожидаемое среднее значение величины, σ – ожидаемое отклонение случайной величины от среднего;
 - У равномерного распределения тоже 2 параметра: a и b , показывающие левую и правую границу области допустимых значений соответственно;
 - У распределения Пуассона 1 параметр: λ , имеющий смысл интенсивности потока случайных событий;
 - ...

Параметры распределения

- У других распределений параметры сложно интерпретируемы или не интерпретируемы вовсе:
 - Бета-распределение с параметрами: α и β
 - Гамма-распределение с параметрами: α и β
 - И т.д.

Параметры распределения

- А сколько численно параметров может быть у распределения?
- 0, 1, 2, 3, ... да сколько угодно!

А как у распределения может быть 0 параметров — это не опечатка?

Распределения в мат.статистике и анализе данных

- Рассмотрим реальную задачу
- Допустим, мы имеем какие-либо данные в качестве выборки, которые мы хотим анализировать
- Чаще всего: известно ли нам, что за распределение имеют данные перед нами?
- Чаще всего: известны ли нам параметры распределения данных перед нами?

Распределения в мат.статистике и анализе данных

- Распределение данных как правило известно
 - Исходя из предметной области
 - Научные статьи
 - Накопленная экспертиза
 - На худой конец, можно сделать предположение и проверить его стат.гипотезой
- Параметры распределения как правило неизвестны

Распределения в мат.статистике и анализе данных

- Рассмотрим пример:
- Известно, что оценки в университете выставляются в среднем по нормальной шкале
- Дана успеваемость группы X курса Y :
[5.7, 6.9, 9.5, 3.2, ...]
- Нарисуйте предполагаемый график распределения оценок на курсе Y , на основе данных из выборки X .

Распределения в мат.статистике и анализе данных

- Очевидно, мы могли бы нарисовать гистограмму распределения значений по группе X. Однако эта гистограмма будет в любом случае построена, исходя из статистических данных
- Нас же просили построить теоретический график плотности распределения оценок
- Для того чтобы это сделать, надо обратиться к уже упоминавшейся сегодня нами теоретической функции плотности нормального распределения:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Распределения в мат.статистике и анализе данных

- Для того чтобы это сделать, надо обратиться к уже упоминавшейся сегодня нами теоретической функции плотности нормального распределения:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

- «Истинные» μ и σ (для генеральной совокупности) мы не знаем. Это и есть параметры распределения, которые как правило нам неизвестны.
- Однако!
- Мы можем их **оценить** по выборке X !

Оценка параметров

Оценка параметров


- Оцениваем неизвестные «истинные» параметры распределения, используя статистические данные
- Более формально: статистическая оценка параметров — это некий функционал от выборки (то есть функция от наблюдений $x_1, x_2, \dots, x_n$)

Оценка параметров

- Оцениваем неизвестные «истинные» параметры распределения, используя статистические данные
- Более формально: статистическая оценка параметров — это некий функционал от выборки (то есть функция от наблюдений $x_1, x_2, \dots, x_n$)
- У оценок бывают различные свойства. Например, «несмещенность», «состоятельность», «эффективность» и тд.
- Свойства оценок показывают, грубо говоря, насколько они точны.
- Мы не будем долго останавливаться на этом, так как сразу будем рассматривать методы, которые дают «хорошие» оценки.


Оценка параметров

- Оцениваем неизвестные «истинные» параметры распределения, используя статистические данные



Оценка параметров

- Оцениваем неизвестные «истинные» параметры распределения, используя статистические данные



Метод моментов

- Что такое моменты? Что такое центральные моменты?
- Моментами и центральными моментами в теории вероятностей называются специальные численные характеристики, описывающие распределение
- Более конкретные формулы (напоминание):
- k -ым моментом (или k -ым начальным моментом) случайной величины X , где $k \in \mathbb{N}$ называется величина

$$v_k = \mathbb{E}[X^k]$$

- k -ым центральным моментом случайной величины X называется

$$\mu_k = \mathbb{E}[(X - \mathbb{E}X)^k]$$

Метод моментов

- Идея метода:
- Зная теоретическое распределение, мы можем выразить моменты через (неизвестные пока) параметры
- Для каждого выбранного теоретического момента, мы можем посчитать соответствующий ему выборочный момент
- Составим уравнения, где теоретические моменты (с неизвестными, которые мы хотим найти) равняются выборочным моментам, которые мы посчитали из данных
- Выразим таким образом все неизвестные нам параметры
- Это и будут точечные оценки этих параметров

Метод моментов

- Идея метода:
- Зная теоретическое распределение, мы можем выразить моменты через (неизвестные пока) параметры
- Для каждого выбранного теоретического момента, мы можем посчитать соответствующий ему выборочный момент
- Составим уравнения, где теоретические моменты (с неизвестными, которые мы хотим найти) равняются выборочным моментам, которые мы посчитали из данных
- Выразим таким образом все неизвестные нам параметры
- Это и будут точечные оценки этих параметров

А сколько нам понадобится
моментов и сколько
уравнений в таком случае?

Метод максимального правдоподобия

- Метод максимального правдоподобия, в отличие от метода моментов, вращается больше вокруг правдоподобия наблюдаемых данных, с условием, что параметры неизвестны.

Метод максимального правдоподобия

- Метод максимального правдоподобия, в отличие от метода моментов, вращается больше вокруг правдоподобия наблюдаемых данных, с условием, что параметры неизвестны.
- Идея метода:
- Строим функцию правдоподобия от выборки, при условии, что параметры являются неизвестными переменными
- Максимизируем функцию правдоподобия по неизвестным параметрам (значения выборки известны)
- В результате получаем такие значения параметров, при которых правдоподобие данных максимальное

Метод максимального правдоподобия

- Идея метода более формально:

$$\max_{\theta_1, \theta_2, \dots, \theta_k} L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_k),$$


- где $\theta_1, \theta_2, \dots, \theta_k$ – неизвестные параметры распределения
- $x_1, x_2, \dots, x_n$ – значения выборки данных, по которым мы оцениваем параметры
- L – функция правдоподобия

Метод максимального правдоподобия

- Как построить функцию правдоподобия? Есть идеи?

Метод максимального правдоподобия

- Как построить функцию правдоподобия? Есть идеи?
- Нам поможет для этого функция плотности распределения



Метод максимального правдоподобия

- Как построить функцию правдоподобия? Есть идеи?
- Функция плотности распределения показывает **относительную** вероятность появления тех или иных значений
- Соответственно, построим функцию, которая будет представлять собой произведение этих относительных вероятностей значений, для каждого имеющегося значения. Чем больше будет относительная вероятность каждого конкретного значения, тем больше будет правдоподобие данных в целом, и тем больше будет наша функция правдоподобия

Метод максимального правдоподобия

- Функция правдоподобия:

$$\begin{aligned} L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_k) \\ = f(x_1, \theta_1, \theta_2, \dots, \theta_k) \cdot f(x_2, \dots) \cdot \dots \cdot f(x_n, \theta_1, \theta_2, \dots, \theta_k) \end{aligned}$$

Метод максимального правдоподобия

- Функция правдоподобия:

$$\begin{aligned} L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_k) \\ = f(x_1, \theta_1, \theta_2, \dots, \theta_k) \cdot f(x_2, \dots) \cdot \dots \cdot f(x_n, \theta_1, \theta_2, \dots, \theta_k) \end{aligned}$$

- Иногда бывает удобнее оптимизировать логарифмическую функцию правдоподобия

Метод максимального правдоподобия

- Функция правдоподобия:

$$\begin{aligned} L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_k) \\ = f(x_1, \theta_1, \theta_2, \dots, \theta_k) \cdot f(x_2, \dots) \cdot \dots \cdot f(x_n, \theta_1, \theta_2, \dots, \theta_k) \end{aligned}$$

- Иногда бывает удобнее оптимизировать логарифмическую функцию правдоподобия

Почему? И когда?

Метод максимального правдоподобия

- Функция правдоподобия:

$$\begin{aligned} L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_k) \\ = f(x_1, \theta_1, \theta_2, \dots, \theta_k) \cdot f(x_2, \dots) \cdot \dots \cdot f(x_n, \theta_1, \theta_2, \dots, \theta_k) \end{aligned}$$

- Иногда бывает удобнее оптимизировать логарифмическую функцию правдоподобия

$$l = \sum_{i=1}^n \log f(x_i, \theta_1, \theta_2, \dots, \theta_k)$$